



Curso: Mestrado Integrado em Engenharia Biomédica
U.C.: Sistemas de Aprendizagem e Extração do Conhecimento

Ficha de Exercícios 04	
Docente:	Hugo Peixoto José Machado
Tema:	Processo de Data Mining
Turma:	PL
Ano Letivo:	2020-2021 – 2º Semestre
Duração da aula:	2 horas

Enunciado

O dataset usado neste exercício é o dataset de doenças cardíacas disponível no ficheiro heart-c.arff, obtido no repositório da UCI. Este dataset descreve fatores de risco para doenças cardíacas. O atributo num representa o atributo da classe (binária):

class <50 - nenhuma doença;
class > 50_1 - aumento do nível de doença cardíaca.

O principal objetivo deste exercício é prever doenças cardíacas a partir de outros atributos no dataset. Obviamente, trata-se de um problema de classificação. O software a ser usado é o Weka. A descrição deste exercício é gradual. Portanto, espera-se que possa entender melhor os vários aspetos e questões envolvidos no processo de KDD.

1. Data Understanding

O primeiro passo para abordar o problema é familiarizar-se com os dados.

Responder às seguintes perguntas ajudará a entender melhor os dados. O dataset heart-c.arff contém algumas informações sobre os dados que armazena. Pode abri-lo num editor de texto.

De seguida carregue o dataset no Weka.

[1] Para cada atributo, encontre as seguintes informações:

[a] O tipo de atributo (p.e. nominal, ordinal, numérico.).

[b] Percentagem de valores ausentes nos dados.

[c] Máx, min, média e desvio padrão (se aplicável).

[d] Existem instâncias que tenham um valor para um determinado atributo que nenhuma outra instância tem, i.e. registos únicos?

[e] Estude o histograma no canto inferior direito e descreva informalmente como o atributo parece influenciar o risco de doença cardíaca. Ao passar o rato pelos gráficos consegue observar umas labels, o que significam?



[2] Mude para o separador *Visualize*, na parte superior da janela, para visualizar gráficos de dispersão 2D para cada par de atributos.

[a] O atributo *thalach* parece estar mais/menos associado a doenças cardíacas? E o atributo *ca*?

[b] Observando os gráficos encontre qual o atributo que parece estar mais correlacionado com o atributo *thalach*. Essa correlação é positiva ou negativa?

[3] Observando o gráfico *thalach*(X) / *oldpeak* (y) Investigue uma possível associação desses atributos com o atributo *class*, ou seja, tente identificar possíveis áreas “densas” de doenças cardíacas (se existirem).

2. Data Processing

A segunda etapa diz respeito ao processamento dos dados de modo a que os dados transformados estejam numa forma mais adequada para os algoritmos de data mining. Todos as alíneas devem partir do ficheiro original.

[1] Seleção de atributos.

Investigue a possibilidade de usar o filtro Weka *AttributeSelection* para selecionar um sub-conjunto de atributos com boa capacidade de previsão. Em seguida, compare os resultados obtidos com as conclusões obtidas na seção anterior. Guarde o conjunto de dados com os atributos selecionados no ficheiro [heart-c1.arff](#).

[2] Lidar com valores ausentes.

Os registos não deverão ser eliminados e é aconselhável atribuir valores onde faltam dados, usando um método adequado. Considere os seguintes métodos para lidar com valores ausentes e investigue cada possibilidade no Weka.

[a] Substitua os valores ausentes pela média do atributo, se o atributo for numérico. Caso contrário, substitua os valores ausentes pela moda do atributo (se o atributo for nominal). Guarde o conjunto de dados que obteve sem valores ausentes no ficheiro [heart-c2.arff](#).

[b] Investigue a possibilidade de usar regressão (linear) para estimar os valores ausentes para cada atributo. Guarde o conjunto de dados que obteve sem valores ausentes no ficheiro [heart-c3.arff](#).

[3] Eliminar outliers.

Investigue a possibilidade de usar o filtro Weka: *Unsupervised -> Attribute -> InterquartileRange* para detectar outliers. (Neste caso para a deteção de outliers deverá apenas selecionar atributos numéricos.)

Ao efetuar a aplicação do filtro encontrará instâncias classificadas como outliers. Reabra o ficheiro *heart-c.arff* e elimine as linhas correspondentes e guarde o conjunto de dados obtido sem outliers no ficheiro [heart-c4.arff](#).



3. Modeling

O terceiro passo é usar algoritmos de classificação disponíveis no Weka para descobrir padrões ocultos nos dados. Deve repetir as etapas descritas abaixo para cada um dos conjuntos de dados criados durante o pré-processamento, além de usar também o dataset original.

[1] Comece com o classificador OneR.

[a] O que pode concluir? Compare as suas conclusões com as conclusões que obteve na seção 1.1.

[b] Compare a precisão do classificador obtida no conjunto de treino (training set) com a estimativa de precisão obtida através do método 10 fold-cross validation. Como explica esta diferença (se existir)?

[2] Use o classificador JRip, ou seja, a versão Weka do classificador de regras RIPPER.

[a] Crie um classificador com e sem rule pruning. Qual se comporta melhor? Justifique a sua resposta.

[3] Use o classificador J48, ou seja, a versão Weka do classificador C4.5 da árvore de decisão.

[a] Explore o uso de diferentes parâmetros no algoritmo J48, como pruning("unpruned") e número mínimo de registos nas folhas("minNumObj").

[b] Descreva os padrões que obteve e compare com as conclusões obtidas nas questões anteriores.

[4] Explore outros algoritmos de classificação e vá guardando os resultados.

4. Evaluation

Na etapa [3] construiu vários modelos. Por fim, é necessário comparar os diferentes modelos e apresentar as suas conclusões.

[1] O Weka oferece várias medidas de avaliação de desempenho. Escolha algumas medidas de desempenho e justifique a sua escolha.

[2] Resuma numa tabela as medidas de desempenho para cada classificador e cada dataset.

[3] O que pode concluir?